

目錄

中文摘要	I	
英文摘要	I	
關鍵詞(keywords)	I	
前言	I	
研究目的		1
文獻探討		1
研究方法		6
結果與討論		13
執行計畫過程遇到之困難或阻礙		14
參考文獻	15	

中文摘要

本計畫旨在探討運用深度學習模型於節奏遊戲《太鼓達人》譜面自動生成之應用與成效比較。透過整理過往文獻，我們選用具代表性的CNN+LSTM模型(如TaikoNation及AGoT)並引入CNN+Transformer模型進行比較實驗。計畫中建立適當的資料集篩選與標準化前處理方法，將.tja格式譜面檔及音訊資料轉換成標籤矩陣與頻譜圖，並進行模型訓練與分析。結果顯示，在中小型資料集及標籤高度稀疏的情況下，CNN+LSTM模型具有較佳的穩定性與預測效果；而CNN+Transformer模型雖具有理論優勢，但在資料不足時容易出現注意力漂移，導致成效不穩定。

英文摘要

This study explores the application and performance comparison of deep learning models for automatic chart generation in the rhythm game "Taiko no Tatsujin." Based on previous studies, we selected the representative CNN+LSTM models (such as TaikoNation and AGoT) and introduced the CNN+Transformer model for comparative experiments. The research established a data filtering and preprocessing pipeline, converting .tja chart files and audio data into label matrices and spectrograms for model training and evaluation. The results show that under small to medium-scale datasets with highly sparse labels, CNN+LSTM models demonstrate greater stability and prediction accuracy. In contrast, while CNN+Transformer models exhibit strong theoretical advantages, they are prone to attention drift when data is insufficient, leading to unstable results.

關鍵詞(keywords)

自動譜面生成、深度學習、CNN、LSTM、Transformer、節奏遊戲、太鼓達人

前言

隨著人工智慧與深度學習技術的快速發展，音樂資訊檢索(Music Information Retrieval, MIR)相關應用蓬勃發展，其中自動譜面生成亦成為熱門研究主題之一。在節奏遊戲領域中，《太鼓達人》是一款廣受歡迎且擁有豐富譜面資料的遊戲，成為研究自動譜面生成的理想平台。過往文獻中，CNN+LSTM架構(如DDC、TaikoNation及AGoT)為前人研究的相關技術，透過卷積神經網路萃取局部特徵、LSTM掌握時序關係，已取得良好成果。然而，隨著Transformer模型在長序列建模上的優勢日益凸顯，結合CNN與Transformer的架構逐漸受到關注。本計畫即旨在比較CNN+LSTM與CNN+Transformer在太鼓達人譜面生成任務中的表現差異，並提出改進方法以提升模型效能。

研究目的

1. 比較CNN+LSTM與CNN+Transformer模型於《太鼓達人》譜面自動生成任務上的表現差異。
2. 探討不同模型架構面對小型資料集及標籤不平衡狀況時之優劣，作為未來研究與系統開發的參考依據。
3. 開發基於BPM及樂理標準的標記演算法，解決過往僅以絕對時間標註所導致的誤差問題。

文獻探討

音樂資訊檢索 (Music Information Retrieval)，簡稱MIR，是一項對於音樂的特徵等進行提取與應用的一門學科，多年來已經被廣泛應用於許多方面，像是搜尋街上播放的音樂的歌曲辨識、抓取特徵的音紋辨識，或是找尋鼓點的節奏辨識[1, 2]，對於音樂製作人、相關行業的從業者或是一般民眾都有許多的用途與幫助。而為了達成音樂檢索資訊的目的，為此提出了多種算法，像是REPET (Repeating Pattern Extraction Technique) [3]等，其中，提出了一個有效的方法，先將音檔進行短時距傅立葉變換 (Short-time Fourier Transform, STFT) 轉換為頻譜圖後，再使用算法對圖片進行檢索，也就是使用圖檔代替音檔作為資料會有更好的效果，這個技術對於等等將會提到的資料處理有著重要的影響。

而近年來，隨著人工智慧潮流的崛起，MIR也隨之引入了深度學習的技術來幫助檢索，使用深度學習來進行檢索音樂特徵有許多好處，因為MIR大多都是提取特徵與辨識，正好是屬於深度神經網路的專長，造就兩個領域一拍即合，而且使用深度神經網路可以提取以前用算法難以量化計算的特徵，使得提取出的特徵更為精準。因為如此，產生了很多應用，像是將一個人的音色轉換成另一個人的音色[4]等，其中，本研究著墨的自動譜面生成也是神經網路輔助MIR的一個例子。

在使用深度學習技術的MIR在輔助節奏遊戲進行譜面生成這領域，最具代表性與開創性的架構為Chris Donahue等人提出的Dance Dance Convolution (DDC) [5]，此架構結合了卷積神經網路 (Convolutional Neural Networks, CNN) 與長短期記憶模型 (Long Short-Term Memory, LSTM) 的CNN+LSTM模型，如下圖1。整份研究對於節奏遊戲的譜面資料的前處理提出了一套標準流程，除了上面提到的先進行STFT將音檔轉為圖檔做為訓練資料，除了能更好地體現特徵，也能更方便地使模型進行卷積，又因為這個模型因為結合了CNN與LSTM，使得這個模型能使用卷積，在一個窗口裡提取整體的特徵之外，也能用LSTM有時序的優點，去分析整首音樂有先後順序的特徵關係，此外，也提出了滑動窗口的概念，使用不同的窗口去提取特徵，能從不同角度更綜觀的分析整段的節奏關係。上述貢獻，對於後來的自動譜面生成有著深遠的影響，之後相關的研究與模型架構整體大多都是參考DDC的架構去進行改良與加深的。




圖1[5], Dance Dance Convolution的網路架構

然而，近年Transformer模型在序列建模的強大能力逐漸受到重視。CNN+ Transformer結構的引入可望解決CNN+LSTM在捕捉長距依賴性與全域關係上的不足。因此，本文將針對CNN+LSTM與CNN+Transformer在太鼓達人譜面生成上的差異進行比較與探討，以下會先對這幾種模型進行簡單介紹。

CNN架構是透過卷積核在局部區域進行特徵萃取，再搭配池化 (Pooling) 層達到降維及避免過度擬合，廣泛應用於影像辨識、音訊分類及時間序列的特徵提取[6]。LSTM則是RNN(Recurrent neural network)的一種變體，藉由引入記憶單元 (Memory Cell) 及三個門控機制 (遺忘門、輸入門、輸出門)，有效處理長期依賴問題，常見於序列生成、音樂預測及語音辨識[7]。Transformer架構如圖2[8]，基於自注意力機制 (Self-Attention)，使模型能同時關注序列中所有元素間的關係，而非局限於前後時間步驟。這使得Transformer能在大規模序列任務中取得突破性進展[9]。




圖2[8], Transformer模型的網路架構

CNN+LSTM模型結合了CNN的空間特徵擷取能力與LSTM的長期時序記憶能力。這種結合讓模型在處理音樂節奏片段時，能同時辨識局部特徵並捕捉長時間的節奏規律[10]。CNN+Transformer架構則進一步融合CNN在低階特徵提取的優勢與Transformer全域注意力機制，能有效捕捉跨時間與跨小節的節奏變化，適用於複雜的節奏預測與生成任務[11]。

在節奏辨識任務上，CNN+LSTM模型已被證實在鼓譜分析與節奏分類中具備高準確率，能有效處理穩定節奏序列。然而，當面對非線性或節拍快速變化的樂曲時，CNN+Transformer架構則展現出更高的靈活性與精準度[12]。類似地，Jaiswal等人在影像標註任務中也證明CNN+Transformer組合優於傳統RNN架構[13]。綜上所述，CNN+LSTM更適合用於具明確結構的節奏辨識任務，而CNN+Transformer則適合應對複雜或高變異性的音樂節奏結構。

本計畫研究的節奏遊戲為『太鼓達人』，以這款遊戲為例，我們將討論不同前人以此為條件進行不同的探討。在過往文獻中，Emily Halina等人提出的TaikoNation[14]，為DDC架構(CNN+LSTM)調整成太鼓達人適合的樣子，開創性的提出了相應的資料處理方法與模型架構，除此之外，裡面強調仿人化製譜(Human-like Patterning)，也就是不能只是單純的根據節奏點去給予記號，還需要根據人類的習慣與偏好給予調整，例如在同樣的節奏點下，若是較輕鬆的間奏時，記號的密度會相比其他部分來得少，反之，在節奏激烈的副歌時也會偏向放入更高密度的記號，以符合實際遊玩時玩家的情緒。以及Ting-Hao Chang提出的AGoT(Automatic Generation of Taiko)[15]，在處理資料時使用模糊標籤(Fuzzy Label)，因為譜面裡記號極度不平均，如此製作成的標籤，導致在模型訓練時大多數都是無記號的無輸出，而在每個記號的前後個插入漸降的值，如下圖3，使模型在訓練時比較不會養成全部無輸出的依賴，以及使用了ROC曲線下方面積(Area under the Curve of ROC, AUC-ROC)來作為正確率的評估，使得模型在依賴全部無輸出時能夠及時發現並改善，整體而言，相比以往提高了7%的準確率，也多少解決記號不平均的問題。




圖3[15]，模糊標籤的圖示範例

然而，雖然前人已提出了相關的基礎作為基底，但仍然有許多的架構與處理可以改良。如TaikoNation裡雖提及需要使用仿人化製譜來使譜面變得更符合玩家習性，而該架構所提出的資料處理方式是藉由絕對時間來作為標籤的依據，也就是在音樂的絕對時間關係下，對譜面進行標記，而在一般樂理上更為常用的是一小節一小節與BPM (Beats Per Minute) 的制度，這就使得資料在標記時無法與樂理上的習慣進行配合，在進行模型訓練時也會忽略掉這個部分，導致相對較難以達成仿人化製譜。以及AGoT在處理資料時使用模糊標籤雖可減輕記號極度不平均的影響，但對於如此龐大空乏標籤，模糊標籤對於改善記號不平均的問題收效也很有限，而且，而交叉熵對於記號不平均的問題也不擅長，造成雖然看得出模型訓練出問題，卻無法讓模型自行調整。

整體而言，將這兩篇較具代表性的太鼓達人自動生成譜面的文獻，與前面敘述到的CNN-Transformer模型，將整體的優劣與可以改善的點，整理製作成表格，如下表1。

表1, 各模型的優缺點分析

模型	優點	缺點
TaikoNation (CNN+LSTM)	仿人化製譜、滑動窗多角度分析	標記依賴絕對時間, 忽略BPM, 長期依賴有限
AGoT (CNN+LSTM)	使用模糊標籤減緩標籤不平衡、評估AUC-ROC提升監控能力	模糊標籤改善有限, 無法根本解決長距依賴性問題
CNN+Transformer	全序列全局視野、多頭注意力、多層特徵交互、可處理跨段落節奏關聯	訓練資料需求高, 模型易過擬合, 需要大規模標準化資料庫支援

從表格中可以發現，前人都是在CNN+LSTM的模型架構下去進行譜面生成的研究，而沒有對於使用CNN+Transformer使用譜面生成的效果，同時TaikoNation與AGoT在前處理的部分也都有所優劣。對於上述問題，我們將針對前人研究有的優缺點進行參考與改進，使得這些問題能夠得到改良。例如前人使用絕對時間對譜面進行標記的問題，本計畫將另提算法，能根據BPM等資訊對譜面進行標記的算法，並在其中解決計算切割、因為精度而產生對不齊導致誤差等問題。此外，也希望透過CNN-Transformer模型有望改善使用CNN+LSTM模型的缺點。

研究方法

資料集收集:

在本研究中，每首歌曲的譜面皆會根據其難易程度進行分級，如圖4所示。以《太鼓達人》(太鼓の達人)遊戲為例，不同等級的譜面在難易度上存在顯著差異。為確保訓練資料的適用性與有效性，本研究選擇難度等級為 6 至 7(困難級)的譜面作為訓練資料。相較於普通級或簡單級的譜面，困難級的譜面保留了較完整的節奏資訊，避免因過多節奏省略而影響訓練效果。同時，相較於魔王級譜面，困難級的譜面通常不會在樂曲中途變更 BPM(每分鐘節拍數)，因此能夠保持訓練資料的一致性。

此外，在篩選訓練資料時，除了依據譜面難度(Level)進行選擇，本研究亦針對譜面檔案(.tja)進行額外過濾。具體而言，我們會檢查譜面是否包含 BPM 變更 (BPMCHANGE) 或小節數調整(MEASURE)的操作，並將包含此類變更的譜面排除，以確保訓練資料的穩定性與一致性。此外，本研究亦要求譜面中的每一小節，其敲擊點須能夠透過縮放方式對齊至 16 個等距單位。若某一小節的敲擊點無法適當地擴大或縮小至 16 個單位，則該譜面亦不納入訓練資料，以確保數據格式的統一性。

此舉可確保資料格式的規範化，避免因節奏分割不均而影響模型的學習效果。透過上述篩選標準，我們能夠提升訓練資料的品質，使模型能在較為一致且規則化的輸入條件下進行學習，進而提高其泛化能力與預測準確度。



圖4, 譜面階級展示圖

前處理(建立資料集):

1.取出文檔

首先將譜面檔案(.tja)輸入至程式，並進行解析以提取關鍵的譜面資訊。程式會讀取檔案中的 BPM(每分鐘節拍數)、offset(時間偏移量)以及各小節中的敲擊點數據。其中，BPM 用來確定歌曲的速度，offset 則調整音樂與譜面之間的對齊。這些關鍵訊息將被提取並儲存，並將作為後續歌曲切割與處理過程中所需的數值輸入。

接著，程式會處理每個小節中的敲擊點數據。在此過程中，會先將每個小節中的所有數值，若不是 1(鼓面)或 2(鼓邊)的敲擊點，將其轉換為 0(不敲擊)。這一步驟的目的是確保模型只處理有效的敲擊點，即鼓面和鼓邊的敲擊點，忽略其他無關的數值，從而減少干擾並提高訓練的效果。

然後，程式將每個小節中的敲擊點數據放大或縮小至 16個時間段，這是為了確保每個小節都具有一致的解析度。當譜面中某個小節的敲擊點數據少於 16個時，程式會將這些敲擊點數據進行放大。放大的方法是根據原始敲擊點數據的長度，將敲擊點依照比例進行重複。以一個例子來說，若原始敲擊點為1201，程式會將其轉換為1111222200001111，這樣可以確保每個時間段都對應到正確的敲擊節奏。

當譜面中的某小節敲擊點數據超過 16個時，程式會對其進行縮小處理。縮小的步驟首先是將該小節中的敲擊點數據數量除以 16，計算出每一小組的敲擊點數量，假設該小節的敲擊點數量為 32，程式則會將該小節分為 16組，並且每組包含 2個敲擊點。接著只要該組內有 1 或 2，該組就會以該敲擊點當作整組的輸出，否則該組的輸出為 0。這樣，經過縮小處理後，每個小節都會保持 16個敲擊點，並確保資料具有該時間段所對應的敲擊點值。

這些處理步驟能確保所有的小節數據都能符合訓練要求，並提高後續模型訓練時的數據一致性。這樣的放大縮小方式，只需在之後模型輸出結果前加入反向的放大縮小，就可以應對敲擊點數量不一的問題，確保模型獲取到的資料永遠都是每小節16個敲擊點的資料。

2.製作標籤:

在將敲擊節奏轉換為標籤格式之前, 程式會先檢查譜面中是否存在前後多餘的全 0 小節。這些小節不含任何敲擊節奏, 會對樂譜與標籤對其造成干擾, 因此需要在標註矩陣之前將其刪除, 確保只有有效的小節參與後續的數據處理與訓練。

接著, 對每一個有效的小節, 程式會檢查每個時間段的敲擊節奏, 並根據其數值進行標註。若該時間段的敲擊節奏為 0, 表示該時刻不需要敲擊, 並將其標註為 $[0,1,0,0]$ 。若敲擊節奏為 1, 表示需要敲擊鼓面上的紅色圈圈, 對應的標籤為 $[0,0,1,0]$; 若敲擊節奏為 2, 則表示需要敲擊鼓邊的藍色圈圈, 對應標籤為 $[0,0,0,1]$ 。

在標註敲擊節奏後, 系統會根據所有訓練歌曲的敲擊點數量來計算補齊值。具體而言, 會讀取每首訓練歌曲的敲擊點數, 並將擁有最多敲擊點數的歌曲的敲擊點數設為補齊值。這樣的補齊方法能確保模型訓練時, 所有資料具有相同的訓練資料量, 並且避免因不同歌曲間的敲擊點數量差異過大而導致訓練效果不一致。

最後, 系統會與預定的補齊值比較。如果該歌曲敲擊點的數量少於補齊目標, 則會用 $[1,0,0,0]$ 將其補充至補齊值的數量, 以確保每首歌訓練資料格式上的一致性。透過這些步驟, 將 .tja 譜面檔案轉換為規範化的訓練資料, 從而提高模型訓練的效果與數據的一致性。

3.音檔處理(資料處理):

在此步驟中, 需將歌曲切分為與標籤中有效敲擊點數量相同的片段, 因此透過讀取文檔步驟所輸出的敲擊點個數與 BPM, 計算每一小段敲擊點所對應的歌曲片段時長。然而, 由於程式無法記錄所有小數點位數, 當歌曲切割至後段時, 累積的誤差可能導致切割出的音檔與標籤無法完全對齊, 進而影響模型的準確性。為了解決此問題, 我們採用了以下方法來持續對齊音檔與標籤。

首先, 針對每個小節的時長, 先進行四捨五入至小數點第三位, 以確保切割時間的數值較易於處理。接著, 計算每一段的實際切割長度之總和, 並將該總和與理想切割長度的累積值進行比較。若二者的差距超過一個單位時間(即誤差超過 0.1%), 則在此次的實際切割長度中補償一個單位時間, 以此方式逐步修正誤差, 使其不會在切割過程中累積並影響對齊結果。

透過此誤差修正算法, 可以有效將誤差縮小至一個單位時間, 使切割出的音檔與標籤在時間軸上保持高度對齊, 同時確保切割出的音檔數量與標籤數量相同。圖5展示了此算法與未修正誤差的切割方式之間的對比, 進一步說明了該方法在時間對齊上的優勢。




圖5, 音檔補齊算法圖

4. 頻譜圖與Reshape:

首先讀取分割好的音訊片段檔案，並轉換為數組。接著，把所有音訊的左右聲道的數據取平均，來將歌曲數據更改為單聲道的形式，以方便將歌曲轉換為頻譜圖。再來，音訊數據會被標準化到 $[-1, 1]$ 範圍內，也就是傅立葉轉換的區間，以便進行後續處理。然後，通過短時傅立葉變換 (STFT) 將音訊數據轉換為頻譜圖，並將其轉換為對數尺度 (dB) 以便顯示低強度信號。

在此過程中，使用 Matplotlib 生成頻譜圖並顯示，並將圖表的坐標軸和邊框去除，使其更加簡潔。生成的頻譜圖會被轉換為 NumPy 陣列，以便後續使用。圖像會被保存為 .jpg 格式並釋放內存，以防止記憶體容量不足。接著，對生成的頻譜圖進行處理，將圖片的較大邊等比例 Reshape 至 $200 * 600$ 個像素，這樣能確保訓練資料的矩陣大小一致，如下圖6所示。所有圖像都會被調整為相同的長寬，這樣可以確證後續模型輸入的資料統一且易於處理。

透過此步驟的處理，能夠將音訊轉換為標準化的頻譜圖並為後續的訓練提供一致的圖像資料，確保模型訓練的穩定性和準確性。




圖6, 頻譜圖樣本

5.合併圖檔與補齊圖檔:

將一首歌的所有圖片包裝進一個矩陣中，但由於每一首的標籤長度皆不一樣，同時也代表，每一首歌的音檔頻譜圖的張數也不一樣，由於模型的輸入必須要矩陣大小一致，因此要先將輸入的每一首歌的頻譜圖矩陣填充至一樣的長度，但由於無歌曲的片段無法用頻譜圖表示，因此無法用任何一種歌曲標籤表示，為了讓模型可以分辨該片段為無歌曲區段，我們以全白色的照片來替代頻譜圖，來額外在訓練模型一個無歌曲區段的種類判斷。並且當要模型訓練完後要輸出猜測的譜面時，只要將該類別的標籤全部去除即不會對輸出產生引響，下圖7為未補齊時的資料矩陣面示意圖，透過此補齊圖檔步驟，來將資料矩陣統一至 1504張資料，如下圖8所示。




圖7, 未補齊時的資料矩陣




圖8, 補齊後的資料矩陣

6.壓縮圖檔:

若要將圖檔或是矩陣進行壓縮，如下圖9所示，其是利用tf.Data中的tf.Features與tf.Example兩個套件來處理壓縮的部分。在壓縮前，由於tf.Features與tf.Example無法儲存矩陣型式的資料，因此要先將頻譜圖與標籤矩陣轉檔成文字檔的形式，以進行訓練資料的壓縮，但由於文字形式的矩陣是將圖片矩陣轉換為一維矩陣儲存，因此若要在解壓縮時轉換回三維矩陣需把原圖片矩陣三維的大小紀錄起來，使一維矩陣能重新轉換回三維矩陣。接著，用tf.Features與tf.Example分別進行壓縮，並將文字形式之頻譜圖、標籤矩陣、頻譜圖之三維大小儲存成TFRecords檔。

當每一首歌各音段頻譜圖壓縮檔後，由於此時的TFRecords檔內只有包含一個敲擊點的訓練資料，但模型的訓練需要一次輸入整首歌，以表示歌曲的連貫性，因此要將原本壓縮完的每一首歌進行解壓縮，並將所有解壓縮完的頻譜圖、標籤矩陣各自依序存入矩陣中，並再次將其壓縮以取的完整一首歌的TFRecords檔。




圖9, TFRecords包裝方式

7.輸入模型:

將每一首歌的壓縮檔放入一個資料夾，在輸入資料的時候將對應batch中的壓縮檔進行解壓縮，來取得該幾首歌的訓練資料矩陣，最終的輸入為幾個大小為[1503, 600, 400, 3]的矩陣中，先透過前處理將圖片的大小從(600, 400)縮小至(60, 40)，並將矩陣的所有數值除以 255來讓矩陣全部數值限縮在 0 到 1之間，也就是做正規化，並將這個正規化矩陣輸入進模型中進行訓練，透過這樣的方式即可將訓練資料以及標籤輸入進模型中。

模型訓練:

模型架構分別如下:

CNN+LSTM	CNN+Transformer
TimeDistributedCNN TimeDistributed(Conv2D) Filters:32 Kernel size:3x3 Padding:'same' Strides:1 輸出 shape:(batch_size, timesteps, 23, 32, 32)	CNNFeatureExtractor Conv2d(3 → 32) kernel_size=3, stride=2, padding=1 批次正規化 + ReLU

TimeDistributed(MaxPooling2D) Pool size: 2x2 輸出 shape: (batch_size, timesteps, 11, 16, 32) TimeDistributed(Conv2D) Filters: 32 Kernel size: 3x3 Padding: 'same' Strides: 1 輸出 shape: (batch_size, timesteps, 11, 16, 32) TimeDistributed(Flatten) 將 (11,16,32) 拉平成向量 (5632,) 輸出 shape: (batch_size, timesteps, 5632) TimeDistributed(Dense) units=256 Activation: ReLU 輸出 shape: (batch_size, timesteps, 256) LSTM units=64 return_sequences=True 輸入 shape: (batch_size, timesteps, 256) 輸出 shape: (batch_size, timesteps, 64) Dense units=4 Activation: softmax 輸出 shape: (batch_size, timesteps, 4)	Conv2d(32 → 64) kernel_size=3, stride=2, padding=1 批次正規化 + ReLU Conv2d(64 → 128) kernel_size=3, stride=2, padding=1 批次正規化 + ReLU AdaptiveAvgPool2d(1,1) Linear(128 → embedding_dim) 最終輸出 shape: (B * seq_length, embedding_dim) CNNTransformerModel 影像特徵提取 CNNFeatureExtractor 將 (B * seq_length, C, H, W) 轉為 (B, seq_length, embedding_dim) 可學習的位置嵌入 (pos_embedding) shape: (1, seq_length, embedding_dim) Transformer Encoder d_model = embedding_dim = 128 多頭注意力 (num_heads) = 8 堆疊層數 (num_layers) = 4 輸出層 (fc_out) Linear(embedding_dim → num_classes)
---	---

訓練皆採用 5 次 epoch

損失函數使用 CrossEntropyLoss

最佳化方法使用 Adam, 學習率為 0.001

結果與討論

將模型輸出轉為譜面後結果如下圖10與圖11，可以發現已具有一般的譜面所有的樣子。



圖10, 模型輸出後轉為譜面的實際樣子



圖11, 訓練結果

而因為譜面為專業的製作人員製作而成，本身並沒有絕對的正確與否，只能從經驗與節奏輔助線去觀察出不同模型的輸出結果的差異，兩個模型輸出的結果的優缺點如下表2。實驗結果可以看出，CNN+LSTM 的表現優於 CNN+Transformer，主要原因在於資料量不足與標籤過於稀疏所帶來的影響。CNN+LSTM 藉由其序列遞迴與長期記憶結構，在高度不平衡標籤分佈(大量標籤為 0)的情況下，能自然地延續趨勢、穩定預測，並有效避免模型陷入不必要的波動。

表2, 各模型輸出結果的優缺點

模型	優點	缺點
CNN+LSTM	同資料量而言訓練時間較短 節奏點比較有抓在節奏上 模型大小較小	節奏點之間的關係較為稀疏 一段區間的節奏關係較為分散
CNN+Transformer	節奏點之間的關係較為明確 一段區間的節奏關係較為強烈	同資料量而言訓練時間較長 節奏點比較沒有抓在節奏上 模型大小較大

相比之下, CNN+Transformer 雖然具備同時捕捉全序列非線性依賴的能力, 理論上適合長序列與複雜節奏辨識, 但當資料量不足、標籤過度稀疏時, Transformer 的多頭注意力機制容易出現「注意力漂移 (attention drift)」現象[16], 模型的注意力權重分散到非關鍵區域, 難以聚焦在真正的節奏點上。此外, Leonardi 等人[17]的研究也指出, Transformer 在面對低資訊密度輸入時, 容易產生上下層語境漂移, 使模型學習效果進一步下降。這解釋了本研究中 CNN+Transformer 無法產生穩定結果的原因。

同時, 資料集規模與序列長度的不同也對模型效能造成顯著影響。根據 Zhang 與 Liu[18]的研究, Transformer 模型在大規模、多樣化的資料集與超長序列條件下能顯著優於 LSTM, 並擅長處理跨段落的節奏關係; 然而, 當資料集小於 10k 或標籤過度偏斜時, Transformer 容易出現過擬合背景訊號、忽略關鍵節奏點的問題[19]。而 CNN+LSTM 模型則能在中小型資料集、節奏規律明顯的場景下維持穩定性, 但隨著序列長度與資料規模增加, 逐漸暴露出梯度消散與運算負擔加重的劣勢[20]。

綜合以上結果, CNN+LSTM 適用於資料量有限且標籤分佈高度稀疏的應用情境, 能穩健處理規則性強、短序列或中等規模任務; 而 CNN+Transformer 雖擁有高度靈活性與跨序列建模能力, 但需要仰賴龐大且平衡的資料集, 否則在稀疏標籤環境下易受注意力漂移影響, 難以有效學習。未來在模型架構選擇上, 應根據資料規模、標籤分佈與音樂類型特徵審慎決策, 以發揮模型最佳效能。

執行計畫過程遇到之困難或阻礙

在本研究計畫執行過程中，曾遇到以下幾項困難與挑戰：

1. 未知曲目之 BPM 與 Offset 自動化取得

在進行新歌曲資料前處理時，必須先獲取曲目的 BPM (Beats Per Minute) 與 Offset (時間偏移量)，而部分歌曲缺乏完整標註。為此，本研究透過撰寫 Python 程式來自動計算並預測未知曲目的 BPM; Offset 則透過將生成譜面前段過多的零標籤自動刪除，並依據刪除長度計算對應時間偏移，有效解決初期人工標記困難問題。

2. 模型訓練過程中發生 OOM (Out of Memory)

在進行模型訓練時，由於資料量大及模型輸入張量尺寸過大，曾多次出現顯示記憶體不足 (OOM) 問題。為解決此狀況，我們透過將頻譜圖進行尺寸縮小處理，以較小圖像輸入模型，同時保留足夠特徵以確保訓練成效，有效降低硬體負擔並避免系統中斷。

3. 正式報告撰寫能力不足

在撰寫專業結案報告時，由於缺乏經驗，難以掌握正式報告格式與用詞風格。為克服此問題，我們透過閱讀很多相關資料、參考前人報告內容並不斷練習修改，使文字表達與格式規範逐步提升。此過程不僅增進了學術寫作能力，也為日後學術研究報告的撰寫打下基礎。

參考文獻

- [1] Masataka, G., & Keiji, H. (2004). Recent Studies on Music Information Processing. *Acoustical Science and Technology*, 25(6), 419–425. <https://doi.org/10.1250/ast.25.419>
- [2] Schedl, M., Gómez, E., & Urbano, J. (2014). Music Information Retrieval: Recent Developments and Applications. *Foundations and Trends® in Information Retrieval*, 8(2-3), 127–261. <https://doi.org/10.1561/15000000042>
- [3] Raffi, Z., & Pardo, B. (2014). REpeating Pattern Extraction Technique (REPET): A Simple Method for Music/Voice Separation. *IEEE Transactions on Audio Speech and Language Processing*, 21(1), 73–84. <https://doi.org/10.1109/TASL.2012.2213249>
- [4] Gabrielli, L., Cella, C., Vesperini, F., Droghini, D., Principi, E., & Squartini, S. (2018, May). *Deep Learning for Timbre Modification and Transfer: An Evaluation Study*. ResearchGate. <https://reurl.cc/pro8Qx>
- [5] Donahue, C., Lipton, zachary C, & Mcauley, J. (2017, January 21). Dance Dance Convolution. *Arxiv*. <https://doi.org/10.48550/arXiv.1703.06891>
- [6] Wu, C., Wang, R., Lu, S., Tian, J., Yin, L., Wang, L., & Zheng, W. (2025). *Time-series data-driven PM_{2.5} forecasting: From theoretical framework to empirical analysis*. *Atmosphere*, 16(3), 292. <https://doi.org/10.3390/atmos16030292>
- [7] Hamzaoui, B., Bouchiha, D., & Bouziane, A. (2025). A comprehensive survey on Arabic text classification: Progress, challenges, and techniques. *Brazilian Journal of Technology*, 8(1). <https://doi.org/10.38152/bjtv8n1-022>
- [8] Sennrich, R., Haddow, B., & Birch, A. (2016). Neural machine translation of rare words with subword units. *arXiv preprint arXiv:1508.07909*. <https://doi.org/10.48550/arXiv.1508.07909>
- [9] Song, X., Niu, Q., Liu, J., Peng, B., Zhang, S., & Liu, M. (2024). Transformer: A Survey and Application. <https://reurl.cc/1K2qvW>
- [10] Devika, P., & Milton, A. (2025). Book recommendation using sentiment analysis and ensembling hybrid deep learning models. *Knowledge and Information Systems*. <https://reurl.cc/3Kj9X0>
- [11] Wang, Y. (2024). Application and analysis of deep learning on sleep quality prediction tasks. In 2024 6th International Conference on Frontier Technologies of Information and Computer (ICFTIC). IEEE. <https://doi.org/10.1109/ICFTIC64248.2024.10913081>
- [12] Saarikka, K., Varsha, V., Harsha, P. S., & Sheikh, A. N. (2025). Deep learning for automated image captioning: A CNN and transformer model analysis. In 2025 3rd International Conference on Intelligent Data Communication Technologies and Internet of Things (IDCIoT). IEEE. <https://doi.org/10.1109/IDCIOT64235.2025.10914740>
- [13] Jaiswal, S., Pallthadka, H., & Chinhewadi, R. P. (2024). Hybrid Vision Transformers and CNNs for Enhanced Image Captioning with Beam Search Optimization. *Technical Gazette*. <https://reurl.cc/j9ko9M>
- [14] Halina, E., & Guzdial, M. (2021, July 26). TaikoNation: Patterning-Focused Chart Generation for Rhythm Action Games. *Arxiv*. <https://arxiv.org/abs/2107.12506>
- [15] Ting-Hao Chang. (2022, June 22). Automatic Generation of Taiko Games Using Deep Learning Methods. <https://reurl.cc/rroolk>

- [16] Welling, C., Longborough, B., & Winterbourne, B. (2024). Semantic Layer Reconstruction in Large Language Models Using Multi-Level Transformer Feedback Mechanisms. *OSF Preprints*. <https://reurl.cc/YY9p4a>
- [17] Leonardi, F., Feldman, P., Almeida, M., & Moretti, W. (2024). Contextual feature drift in large language models: An examination of adaptive retention across sequential inputs. *OSF Preprints*. <https://reurl.cc/kn7gM3>
- [18] Zhang, M., & Liu, D. (2024). CNN–LSTM based multimodal models for music generation. In *2024 IEEE International Symposium on Parallel and Distributed Processing with Applications (ISPA)*. IEEE. <https://doi.org/10.1109/ISPA63168.2024.00117>
- [19] Wu, Y. F., Liu, X., Gan, X., & Li, W. (2023). XBeat: A Hybrid CNN-Transformer Model for Beat and Downbeat Tracking. *National Conference on Sound and Music Computing*. <https://reurl.cc/lz9AyA>
- [20] El Achkar, C. (2023). Music encoding and deep learning for music transcription and classification based on visually represented audio features. *HAL Science Theses*. <https://reurl.cc/xNOAve>