

運用深度學習於節奏遊戲《太鼓達人》譜面自動化生成技術

Ho Ethan, Chiang Jimmy, 老師

NTUT

July 16, 2025

1 目的

在數位音樂與互動娛樂蓬勃發展的今日，如何透過人工智慧提升音樂內容的理解與生成能力，成為跨領域研究的重要目標。音樂資訊檢索 (Music Information Retrieval, MIR) 技術正逐步拓展應用範疇，從傳統的旋律辨識與風格分類，延伸至音訊標註、自動伴奏、以及遊戲互動等場景。其中，「自動譜面生成 (Automatic Chart Generation)」因需同時處理聲音特徵解讀、節奏結構分析與人類行為模擬，被視為整合 MIR、深度學習與人機互動的重要挑戰。

在眾多應用情境中，節奏遊戲提供了獨特且具代表性的研究平台。尤其是《太鼓達人》這類譜面規則明確、節奏切分清晰的遊戲，具備理想的資料結構與標註格式，成為進行譜面生成技術驗證的絕佳實驗場域。該遊戲每首譜面皆對應特定音樂片段、節奏結構與敲擊類型，提供一對一且可量化的訓練樣本，對於資料驅動的模型學習具有極高價值。此外，社群創作與公開競賽亦產出大量高品質譜面資料，有助於建立具代表性的資料集與評估基準。

儘管如此，自動譜面生成仍面臨多重技術挑戰。首先，譜面中的敲擊標記呈高度稀疏分布，多數時間點無擊打事件，導致模型在訓練時面臨標記不平衡問題。其次，許多早期研究將敲擊點視為獨立預測事件，忽略音樂中的全域節奏脈絡（如 BPM、小節與樂句），使生成結果缺乏音樂性與結構性。第三，雖然 CNN 結合 LSTM 之架構已被廣泛應用於節奏建模，如 DDC [1] 與 TaikoNation [2]，但其時間記憶能力有限，難以捕捉長距離節奏依賴關係，對於具有多段落或變化節奏的音樂片段尤為明顯。

為克服上述限制，近期有研究開始引入 Transformer 架構。其自注意力機制 (Self-Attention) 可直接建模全序列中任意時間點間的相依關係，理論上具備強大的結構學習潛力。AGoT [3] 則嘗試使用模糊標籤與 ROC-AUC 指標來處理標記稀疏性，雖提升穩定性，仍未解決長距建模與節奏準確的根本問題。

然而，目前鮮少研究深入探討 CNN+Transformer 架構在《太鼓達人》這類固定節奏格式下的應用表現，特別是在小樣本或標註稀疏條件下的可行性、穩定性與模型行為。Transformer 雖強大，卻亦高度仰賴大量標準化資料訓練，否則容易出現注意力漂移 (Attention Drift)、上下文失衡與過擬合等問題 [4], [5]。因此，在實際節奏遊戲應用中，其效能與侷限尚需更詳實的分析與實證支撐。

基於此研究動機，本研究設計並實作一套針對《太鼓達人》自動譜面生成的完整系統，並針對 CNN+LSTM 與 CNN+Transformer 兩種主流架構進行深入比較。我們提出具備 BPM 對齊、節奏離散化與長度補齊之前處理流程，並設計標準化的音訊頻譜圖轉換與標記格式，以消除原始資料的非一致性。透過設計統一訓練流程與後處理機制，本研究可在同一條件下，系統性評估兩種架構於譜面生成任務中的效能差異與輸出品質。

此外，本研究亦特別關注 Transformer 架構在中小型

資料集下的實務行為，包括訓練穩定性、預測節奏準確度與結構一致性。藉由量化指標 DCRand、DCHuman 與 OCHuman，我們從節奏結構性、與人工譜面相似度，以及節奏容忍性等層面進行全面性比較，進一步揭示各架構之優勢、侷限與應用情境。

本研究的貢獻包括：

- 提出一套完整的《太鼓達人》自動譜面生成流程，整合資料清洗、節奏標註與頻譜圖轉換，強化模型輸入一致性與樂理結構準確性。
- 系統性比較 CNN+LSTM 與 CNN+Transformer 架構於不同資料條件下的學習行為與生成結果，填補既有研究空白。
- 分析 Transformer 架構於低密度標註資料下的潛在問題，並提出補齊機制與後處理策略改善其生成穩定性與節奏感知能力。
- 相較於現有模型，本研究在 DCHuman 指標上展現優異表現，其中 CNN+Transformer 模型最高可達 0.9729，CNN+LSTM 模型亦達 0.9637，平均分數分別為 0.8824 與 0.9424，顯示本系統在譜面與人工譜面整體相似度方面具備高度準確性。

本研究期望透過上述方法與實驗，為節奏遊戲中的深度學習應用建立更明確的模型選擇依據與技術路徑，並為後續自動化製譜、擬人化節奏設計與遊戲 AI 提供堅實的理論與實務基礎。

2 文獻回顧

深度學習技術自 2010 年代後期迅速進入音樂資訊檢索 (MIR) 領域，並推動多項應用技術躍進，如旋律追蹤、節奏感知、聲音來源分離與音訊生成等 [6], [7]。其中，自動譜面生成 (Automatic Chart Generation) 結合了 MIR、計算機聽覺與行為模擬等子領域，是節奏遊戲相關研究中的核心技術之一。

初期研究大多著重於將音訊訊號轉為頻譜圖，並藉由卷積神經網路 (CNN) 擷取局部特徵，再交由遞迴神經網路如 LSTM 處理時間序列資訊。Donahue 等人提出的 Dance Dance Convolution (DDC) 模型為此類方法的代表 [1]，成功應用於《Dance Dance Revolution》等遊戲譜面生成，為後續研究奠定技術基礎 [8]。

在針對《太鼓達人》的研究中，TaikoNation 系統 [2] 首次將仿人化概念 (Human-like Patterning) 導入節奏遊戲譜面生成任務，並沿用 CNN+LSTM 架構，模擬人類編曲者對音符密度與節奏流暢性的控制。然而，其標記方式僅基於絕對時間，未納入 BPM、小節與拍點資訊，導致生成譜面在節奏與結構對齊上仍有所欠缺。

AGoT 系統 [3] 則針對譜面標記稀疏問題進行改良，引入模糊標籤（Fuzzy Label）機制，以連續值取代二值敲擊標記，降低訓練過程中對「無敲擊」樣本的過度依賴。該研究亦採用 ROC-AUC 作為評估指標，有效提升模型訓練穩定性。然而，AGoT 雖可處理標記稀疏問題，卻仍無法捕捉長距節奏關聯與節奏變化趨勢。

在序列建模能力上，Transformer 架構近年已證明其在語言與音訊任務中具備顯著優勢，特別是在長序列學習與全域注意力控制上 [9], [10]。近期研究開始探討 CNN 與 Transformer 的結合應用於影像字幕、節奏識別與音訊理解等任務 [11]–[13]，並呈現出比 LSTM 更強的結構建模能力。然而，Transformer 架構對資料規模與標記密度極度敏感，特別是在樣本數不足時，常產生注意力漂移（Attention Drift）、上下層語境失衡與過擬合等問題 [14]–[16]。

Zhang 與 Liu 的研究指出 Transformer 架構雖能在大規模資料集上表現良好，但在小樣本環境中將面臨顯著效能下降與泛化困難 [4]。Wu 等人亦提出類似觀察，並建議結合卷積層與 Transformer 可改善節奏感知任務之性能穩定性 [5]。

綜合上述文獻可知，雖已有諸多系統針對《太鼓達人》譜面自動生成進行設計，然而多數方法仍侷限於單一模型架構或特定標記方式，尚缺乏對不同神經網路架構之系統性比較與分析。特別是 CNN+Transformer 架構於中小型資料集與標記稀疏條件下之行為表現與優劣仍未釐清。本研究即致力於填補此一研究空缺，針對 CNN+LSTM 與 CNN+Transformer 兩種主流架構進行系統性比較，提出改良方法並建立實證基準，為未來譜面生成系統之設計提供可行依據 [17]。

3 方法

3.1 系統架構

本研究之自動譜面生成系統，設計核心流程包含資料集蒐集、譜面檔與音檔的同步前處理、標籤製作、音訊頻譜圖轉換、資料補齊與壓縮，以及深度學習模型訓練和推論。此流程確保所有資料進入模型前已標準化，並解決原始音樂資料與譜面資料在格式、長度與對齊上的問題，提升模型學習效率及預測效果，其整體系統流程如圖 1 所示。




Figure 1: 系統流程圖

3.2 限制條件

本研究僅適用於滿足特定條件的情境下，才能確保數據處理與譜面生成的正確性與一致性。首先，必須具備完整的 offset、BPM 等譜面關鍵數據，才能依據樂理進行切割與對齊，確保標籤與音訊的同步。若缺少這些資訊，將無法精確對應音檔與譜面，導致後續標註與切割失效。

再者，本研究僅適用於像《太鼓達人》這類「敲擊點數量固定」的節奏遊戲，即每小節內敲擊點數可透過縮放對齊至固定解析度（如 16 點），而不適用於以「絕對時間點」標註敲擊事件的遊戲。如文中所述，譜面中的每一小節，其敲擊點須能夠透過縮放方式對齊至 16 個等距單位。若某一歌曲中任一小節的敲擊點無法適當地擴大或縮小至 16 個單位，則該譜面亦不納入訓練資料，以確保數據格式的統一性。

此外，為了確保訓練資料的一致性，本研究僅選用 BPM 固定、不含變速的譜面。系統會自動檢查譜面檔案 (.tja) 是否包含 BPM 變更（如 BPMCHANGE 指令），並將這類曲目排除在訓練資料之外，以避免變速導致的資料對齊和標註錯誤。

因此，本研究僅能運用在具備完整譜面資訊、敲擊點分布可被離散化處理，且 BPM 不會變化的遊戲類型中。若缺乏上述任一條件，方法的步驟將無法成立，也會影響後續模型訓練與譜面輸出品質。

3.3 系統架構

3.3.1 過濾敲擊點

本研究首先，將 .tja 譜面檔輸入程式解析，取得 BPM、offset 以及各小節的敲擊點資料。接著，對每個小節中的數值進行過濾，將所有非 1（鼓面）或 2（鼓邊）的敲擊點統一轉換為 0（不敲擊），以確保模型僅處理有

效敲擊事件，降低雜訊並提升訓練效果。在進行標註前，程式亦會先檢查並刪除譜面前後多餘的全 0 小節，避免這些空白區段影響標註與後續訓練品質。經過這些步驟，最終僅保留包含實際敲擊資訊的小節作為後續處理與訓練之用。

3.3.2 重整長度

為消弭原始譜面中不同小節間敲擊數量的不一致，系統會將每小節的敲擊資料透過插值（放大）或分組取樣（縮小）轉換為固定 16 個時間段。例如，若某小節原本僅 4 個敲擊點，會依比例複製並排列成 16 位元；反之，若多於 16 點，則以分組最大值進行下採樣。

此步驟可確保所有小節資料格式一致，利於深度學習模型批次訓練。未來模型推論產生結果時，僅需執行反向縮放即可回復原始小節長度，進一步解決資料長度不一的問題，並同時提升譜面自動生成系統的穩定性。

3.3.3 製作標籤

此步驟會檢查每個時間段的敲擊節奏，並根據其數值進行標註。為了方便模型進行多分類學習，本研究採用 one-hot 向量的方式表示每個時間點的敲擊狀態。若該時間段的敲擊節奏為 0，表示不需要敲擊，標註為 [0,1,0,0]；若為 1，代表需敲擊鼓面上的紅色圈圖，標註為 [0,0,1,0]；若為 2，代表需敲擊鼓邊的藍色圈圖，標註為 [0,0,0,1]。此種標記方式能讓模型明確分辨每一類型的敲擊事件，提升訓練與推論的準確度。

3.3.4 標籤長度補齊

在標註敲擊節奏後，系統會統計所有訓練歌曲的敲擊點數，並以其中最多者作為補齊值。每首歌曲的標籤資料若未達補齊長度，則以補齊標籤補足，使所有輸入資料在模型訓練時具有相同長度。此設計可避免因歌曲間敲擊點數差異過大，導致模型訓練效果不一致，提升整體訓練的穩定性。

系統會將每首歌曲的敲擊點數與補齊值比較，如果該歌曲敲擊點的數量少於補齊目標，則會用 [1,0,0,0] 將其補充至補齊值的數量，以確保每首歌訓練資料格式上的一致性。以將.tja 譜面檔案轉換為規範化的訓練資料，從而提高模型訓練數據的一致性。

3.3.5 壓縮檔案

若要将圖檔或是矩陣進行壓縮，如下圖所示，其是利用 tf.Data 中的 tf.Features 與 tf.Example 兩個套件來處理壓縮的部分。在壓縮前，由於 tf.Features 與 tf.Example 無法儲存矩陣型式的資料，因此要先將頻譜圖與標籤矩陣轉檔成文字檔的形式，以進行訓練資料的壓縮，但由於文字形式的矩陣是將圖片矩陣轉換為一維矩陣儲存，因此若要在解壓縮時轉換回三維矩陣需把原圖片矩陣三維的大小紀錄起來，使一維矩陣能重新轉換回三維矩陣。接著，用 tf.Features 與 tf.Example 分別進行壓縮，並將文字形式之頻譜圖、標籤矩陣、頻譜圖之三維大小儲存成 TFRecords 檔。




Figure 2: TFRecord 範例圖

3.3.6 切除無聲片段

本步驟透過「過濾敲擊點」所取得的 offset 及計算得出的有效譜面總時長，來判斷整首音樂中實際有敲擊事件的時間範圍。藉此，可在進行音檔切割時，同步移除音樂前後無聲或無敲擊的片段，使得後續的資料處理與模型訓練僅針對實際含有譜面資料的音訊內容，提升資料品質與訓練效率。

3.3.7 切割長度計算與切割音檔

需將歌曲切分為與標籤中有效敲擊點數量相同的片段，因此透過讀取文檔步驟所輸出的敲擊點個數與 BPM，計算每一小段敲擊點所對應的歌曲片段時長。然而，由於程式無法記錄所有小數點位數，當歌曲切割至後段時，累積的誤差可能導致切割出的音檔與標籤無法完全對齊，進而影響模型的準確性。為了解決此問題，我們採用了以下方法來持續對齊音檔與標籤。

首先，針對每個小節的時長做四捨五入至小數點第三位，以確保切割時間的數值較易於處理。接著，計算每一段的實際切割長度之總和，並將該總和與理想切割長度的累積值進行比較。若二者的差距超過一個單位時間（即誤差超過 0.1%），則在此次的實際切割長度中補償一個單位時間，以此方式逐步修正誤差，使其不會在切割過程中累積並影響對齊結果。此誤差修正算法，可以有效將誤差縮小至一個單位時間，使切割出的音檔與標籤在時間軸上保持高度對齊，同時確保切割出的音檔數量與標籤數量相同。




Figure 3: 切割長度計算

3.3.8 頻譜圖轉換

首先讀取分割好的音訊片段檔案，並轉換為數字數組。接著，把所有音訊的左右聲道的數據取平均，來將歌

曲數據更改為單聲道的形式，以方便將歌曲轉換為頻譜圖。再來，音訊數據會被標準化到 $[-1, 1]$ 範圍內，也就是傅立葉轉換的區間，以便進行後續處理。然後，通過短時傅立葉變換 (STFT) 將音訊數據轉換為頻譜圖，並將其轉換為對數尺度 (dB) 以便顯示低強度信號。並將其轉 Reshape 至 200×600 個像素，這樣能確保訓練資料的矩陣大小一致，如下圖 6 所示。所有圖像都會被調整為相同的長寬，這樣可以確證後續模型輸入的資料統一且易於處理。




Figure 4: 頻譜圖範例

3.3.9 頻譜圖長度補齊

正如「標籤長度補齊」所述，頻譜圖資料也需要進行補齊處理。當某首歌的頻譜圖數量少於標準長度時，會在末尾補上全白頻譜圖，使其總數與補齊後的標籤長度一致。如此設計可確保所有訓練資料在輸入模型時維持相同的維度與格式，有助於提升模型訓練的穩定性與效能。此外，補齊部分以全白頻譜圖表示，也能讓模型明確區分實際音訊與補齊區段，避免非實際資料對學習造成干擾。




Figure 5: 頻譜圖長度補齊

3.3.10 模型處理

為了降低運算負擔，頻譜圖會先縮小至較小的尺寸 (如 60×40 像素)，並將像素值歸一化至 0 至 1 之間。接著，分別用 CNN+LSTM 和 CNN+Transformer 兩種深度學習模型架構，以進行敲擊點的預測，模型架構如下圖所示。

CNN+LSTM	CNN+Transformer
TimeDistributedCNN TimeDistributed(Conv2D) Filters : 32 Kernel size : 3x3 Padding : 'same' Strides : 1 輸出 shape : (batch_size, timesteps, 23, 32, 32) TimeDistributed(MaxPooling2D) Pool size : 2x2 輸出 shape : (batch_size, timesteps, 11, 16, 32) TimeDistributed(Conv2D) Filters : 32 Kernel size : 3x3 Padding : 'same' Strides : 1 輸出 shape : (batch_size, timesteps, 11, 16, 32) TimeDistributed(Flatten) 將 (11,16,32) 拉平成向量 (5632,) 輸出 shape : (batch_size, timesteps, 5632) TimeDistributed(Dense) units=256 Activation : ReLU 輸出 shape : (batch_size, timesteps, 256) LSTM units=64 return_sequences=True 輸入 shape : (batch_size, timesteps, 256) 輸出 shape : (batch_size, timesteps, 64) Dense units=4 Activation : softmax 輸出 shape : (batch_size, timesteps, 4)	CNNFeatureExtractor Conv2d(3 → 32) kernel_size=3, stride=2, padding=1 Batch Normalization + ReLU Conv2d(32 → 64) kernel_size=3, stride=2, padding=1 Batch Normalization + ReLU Conv2d(64 → 128) kernel_size=3, stride=2, padding=1 Batch Normalization + ReLU AdaptiveAvgPool2d(1,1) Linear(128 → embedding_dim) Output shape : (B * seq_length, embedding_dim) CNNTransformerModel Image Feature Extraction CNNFeatureExtractor Transform (B * seq_length, C, H, W) to (B, seq_length, embedding_dim) Learnable Positional Embedding(pos_embedding) shape : (1, seq_length, embedding_dim) Transformer Encoder d_model = embedding_dim = 128 num_heads = 8 num_layers = 4 Output Layer (fc_out) Linear(embedding_dim → num_classes)

Figure 6: 系統流程圖

在訓練階段，模型均以 5 個 epoch 進行學習，並採用 CrossEntropyLoss 作為損失函數，最佳化方法則選用 Adam，學習率設為 0.001。此設定能在有限資料條件下，維持模型的穩定訓練與良好泛化能力。

3.3.11 模型後處理

在模型預測階段結束後，會針對模型輸出的每一類別 (無敲擊、紅面、藍邊、無聲片段) 分別計算其預測值的平均數。接著，每一個敲擊點的模型預測結果中只要任一類別的值大於該類別的平均值，該敲擊點就會被標記為對應的類別。此方法能夠根據模型的輸出分布，動態選取適合的判斷門檻，有效提升最終譜面標註的準確度與一致性，同時也能避免僅以固定閾值導致的偵測偏差，讓結果更貼近實際節奏特徵。

3.4 評量指標

為了客觀評估本研究所產生之譜面結果是否具備結構性與音樂性，我們設計並採用三項評估指標，分別對應於隨機性差異、整體相似度與時序對齊能力：

- **DCRand (Direct Comparison against Random)**
本指標將模型輸出譜面轉換為 0,1,2 表示後，與隨機

產生之噪聲譜面逐時點（一對一）比對，統計其匹配比例。DCRand 反映模型輸出與純隨機結果的結構差異，分數越高表示模型產出越具組織性與節奏規律，越不像隨機產物。

• DCHuman (Direct Comparison against Human)

DCHuman 為模型輸出譜面與人工譜面之間的逐時點比對，以人工譜面作為標準檔案，統計兩者於所有時間點上的正確率。此指標可視為傳統分類準確率，能提供生成結果與人為編輯譜面整體相似度的衡量。

• OCHuman (Onset Comparison with Scale against Human)

OCHuman 在 DCHuman 的基礎上，進一步引入 ± 1 時間點之容許誤差範圍。當人類譜面中某一敲擊點在模型輸出中對應位置缺失時，系統將額外檢查前後相鄰時間點是否存在有效擊點。此一設計可更真實地評估模型對擊點時間的掌握能力，具備更高容錯性，尤其適用於節奏遊戲中允許些微誤差的應用場景。

4 結果

實驗共使用 30 筆 CNN+Transformer 產出結果與 11 筆 CNN+LSTM 結果，並以三項指標：DCRand（與亂數一致率）、DCHuman（與人類譜面相似度）及 OCHuman（寬容節奏點準確度）進行性能評估。

本節亦納入《TaikoNation》論文中之基準模型 TaikoNation (CNN+LSTM) 與 DDC (Dance Dance Convolution) 作為對照，進行全面性比較。




Figure 7: 譜面圖展示
[18]

4.1 量化結果對照

表 3 彙整本研究模型與論文模型之三項指標平均表現。可以觀察到，CNN+LSTM 在 OCHuman 上表現最佳，達到 0.9424，顯著高於論文中的 TaikoNation (0.7932) 與 DDC (0.8345)；而 CNN+Transformer 雖在 OCHuman 亦有不錯表現 (0.8824)，但在 DCHuman 表現略優於 CNN+LSTM (0.5173 對 0.4174)，整體與人類譜面的匹配度仍與論文模型有明顯差距。

表 1 顯示各模型於 OCHuman 最佳表現下之各評量指標。其中 CNN+Transformer 在 OCHuman 上最高達 0.9729，驗證其節奏對應能力。

表 2 顯示各模型於 DCHuman 最佳表現下之各評量指標。其中 CNN+Transformer 在 DCHuman 上僅達 0.5918，明顯低於論文基準模型 DDC (約 0.779)。

4.2 分析與討論

CNN+LSTM 模型在節奏點的容忍匹配能力 (OCHuman) 中表現優異，其最佳表現高達 0.9637，平均亦達到 0.9424。這說明 CNN+LSTM 架構能有效且穩定地捕捉節奏點的時間資訊，成功克服標籤高度稀疏的限制。然而，在敲擊類型的準確性 (DCHuman) 方面則明顯較低，平均僅達 0.4174，最佳樣本表現也僅為 0.4736。此結果反映出 CNN+LSTM 雖然能準確掌握敲擊的時間點，但受限於其時序記憶特性，無法有效處理更複雜的節奏結構與類型分佈，從而導致生成譜面在內容豐富性與變化性上有所不足。

相較之下，CNN+Transformer 模型在敲擊類型選擇 (DCHuman) 上展現出較佳的性能，平均達 0.5173，最佳表現甚至達到 0.5918，顯示其具備更為全面且有效的節奏語意擬合能力。此外，CNN+Transformer 在寬容節奏點準確性 (OCHuman) 亦具有高度競爭力，最佳成績高達 0.9729，說明 Transformer 架構的自注意力機制確實能有效捕捉節奏序列中的非線性依賴。然而值得注意的是，CNN+Transformer 模型的亂數一致率 (DCRand) 相對較高，最佳可達 0.5536，這表明其生成譜面在結構上仍存在部分隨機性，暗示在標籤稀疏與資料量有限的情況下，注意力可能出現漂移，使得部分節奏點缺乏明確對應。

綜合 Table 3, Table 1 與 Table 2 數據來看，CNN+LSTM 架構在節奏穩定性與拍點對齊的能力上有顯著優勢，而 CNN+Transformer 架構則在節奏風格與仿人化敲擊類型預測方面更具潛力。兩種模型皆展示了在不同情境下的應用優勢，證明在資料不足情況下亦能取得具體成效。

未來研究可針對 Transformer 架構進行補強，如加入節奏記憶編碼 (rhythm-aware encoding)、Pattern-aware Loss 或多尺度注意力機制 (multi-scale attention)，有望進一步提升其穩定性與結構性。此外，LSTM 架構則可透過引入階層式節奏建模策略，改善其長距離依賴的捕捉能力，進一步提升其在節奏類型預測上的準確性。

4.3 未來研究方向

從實驗結果可見，CNN+Transformer 架構具備良好之節奏感應能力 (OCHuman 高)，但其仿人化結構生成能力仍待提升。未來可考慮引入 Pattern-aware Loss、節奏片段標記機制，或採用多尺度注意力模型以提升長距離節奏結構的理解能力。

此外，考量 Transformer 架構對資料量與標註密度高度敏感，亦建議在訓練階段使用更大規模且多樣化的標準譜

Table 1: 各模型於 OCHuman 最佳表現下之各評量指標

指標	CNN+Transformer	CNN+LSTM
DCRand	0.5536	0.5676
DCHuman	0.5170	0.4083
OCHuman	0.9729	0.9637

Table 2: 各模型於 DCHuman 最佳表現下之各評量指標

指標	CNN+Transformer	CNN+LSTM
DCRand	0.5191	0.5573
DCHuman	0.5918	0.4736
OCHuman	0.9119	0.9180

面數據，以避免注意力漂移與過擬合問題，進而強化其實務應用表現。

5 結論

本研究提出並實作了一套完整的自動譜面生成系統，透過系統性的資料前處理、頻譜圖轉換與標籤補齊策略，有效克服《太鼓達人》譜面生成中資料稀疏、節奏結構不明確及資料對齊誤差的問題。實驗結果顯示，CNN+LSTM 模型在有限資料量與高度稀疏的標籤條件下表現出較佳的穩定性與節奏掌握能力，其中 OCHuman 指標最高達到 0.9424；CNN+Transformer 模型則展現了更佳的全序列建模潛力，在節奏容忍度（OCHuman）上表現尤為突出（最高達 0.9729），但其仍存在注意力漂移與結構穩定性不足等挑戰。因此，未來研究可進一步透過導入 Pattern-aware Loss 函數、節奏片段標記策略及多尺度注意力機制，改善 Transformer 架構在節奏結構的仿人化與泛化能力。此外，也建議擴大資料集規模與提高標註密度，以提升實際應用的效能與穩定性。

Table 3: 本研究與既有模型於各指標之平均表現

指標	CNN+Transformer	CNN+LSTM	TaikoNation	DDC
DCRand	0.4974	0.5758	0.5041	0.4994
DCHuman	0.5173	0.4174	0.7499	0.7790
OCHuman	0.8824	0.9424	0.7932	0.8345

References

- [1] C. Donahue, Z. C. Lipton, and J. McAuley, *Dance dance convolution*, 2017. arXiv: arXiv : 1703 . 06891. [Online]. Available: <https://arxiv.org/abs/1703.06891>.
- [2] E. Halina and M. R. Guzdial, *Taikonation: Patterning-focused chart generation for rhythm action games*, 2021. [Online]. Available: <https://arxiv.org/abs/2107.12506>.
- [3] T.-H. Chang, *Automatic generation of taiko games using deep learning methods*, 2022. [Online]. Available: <https://reurl.cc/rroolk>.
- [4] M. Zhang and D. Liu, “Cnn-lstm based multimodal models for music generation,” in *2024 IEEE International Symposium on Parallel and Distributed Processing with Applications (ISPA)*, IEEE, 2024. DOI: 10.1109/ISPA63168.2024.00117.
- [5] Y. F. Wu, X. Liu, X. Gan, and W. Li, *Xbeat: A hybrid cnn-transformer model for beat and downbeat tracking*, National Conference on Sound and Music Computing, 2023. [Online]. Available: <https://reurl.cc/lz9AyA>.
- [6] G. Masataka and H. Keiji, *Recent studies on music information processing*, Acoustical Science and Technology, 25(6), 419–425, 2004. DOI: 10.1250/ast.25.419. [Online]. Available: <https://doi.org/10.1250/ast.25.419>.
- [7] M. Schedl, E. Gómez, and J. Urbano, *Music information retrieval: Recent developments and applications*, Foundations and Trends in Information Retrieval, 8(2-3), 127–261, 2014. DOI: 10.1561/15000000042. [Online]. Available: <https://doi.org/10.1561/15000000042>.
- [8] C. El Achkar, *Music encoding and deep learning for music transcription and classification based on visually represented audio features*, HAL Science Theses, 2023. [Online]. Available: <https://reurl.cc/xN0Ave>.
- [9] R. Sennrich, B. Haddow, and A. Birch, *Neural machine translation of rare words with subword units*, arXiv preprint arXiv:1508.07909, 2016. arXiv: 1508 . 07909 [cs.CL]. [Online]. Available: <https://doi.org/10.48550/arXiv.1508.07909>.
- [10] Y. Wang, *Application and analysis of deep learning on sleep quality prediction tasks*, In 2024 6th International Conference on Frontier Technologies of Information and Computer (ICFTIC), IEEE, 2024. DOI: 10.1109/ICFTIC64248.2024.10913081. [Online]. Available: <https://doi.org/10.1109/ICFTIC64248.2024.10913081>.
- [11] B. Hamzaoui, D. Bouchiha, and A. Bouziane, *A comprehensive survey on arabic text classification: Progress, challenges, and techniques*, Brazilian Journal of Technology, 8(1), 2025. DOI: 10.38152/bjtv8n1-022. [Online]. Available: <https://doi.org/10.38152/bjtv8n1-022>.
- [12] K. Saarikka, V. Varsha, P. S. Harsha, and A. N. Sheikh, *Deep learning for automated image captioning: A cnn and transformer model analysis*, In 2025 3rd International Conference on Intelligent Data Communication Technologies and Internet of Things (IDCIoT), IEEE, 2025. DOI: 10.1109/IDCIoT64235.2025.10914740. [Online]. Available: <https://doi.org/10.1109/IDCIoT64235.2025.10914740>.
- [13] S. Jaiswal, H. Pallthadka, and R. P. Chinhewadi, *Hybrid vision transformers and cnns for enhanced image captioning with beam search optimization*, Technical Gazette, 2024. [Online]. Available: <https://reurl.cc/j9ko9M>.
- [14] C. Welling, B. Longborough, and B. Winterbourne, *Semantic layer reconstruction in large language models using multi-level transformer feedback mechanisms*, <https://reurl.cc/YY9p4a>, 2024.
- [15] F. Leonardi, P. Feldman, M. Almeida, and W. Moretti, *Contextual feature drift in large language models: An examination of adaptive retention across sequential inputs*, <https://reurl.cc/kn7gM3>, 2024.
- [16] X. Song, Q. Niu, J. Liu, B. Peng, S. Zhang, and M. Liu, *Transformer: A survey and application*, Online, 2024. [Online]. Available: <https://reurl.cc/1K2qvW>.
- [17] C. Wu, R. Wang, S. Lu, et al., *Time-series data-driven pm_{2.5} forecasting: From theoretical framework to empirical analysis*, Atmosphere, 16(3), 292, 2025. DOI: 10.3390/atmos16030292. [Online]. Available: <https://doi.org/10.3390/atmos16030292>.
- [18] 太鼓さん次郎有志ユーザー, 太鼓さん次郎 (tja) 関連ツール, <https://wikiwiki.jp/taiko/> (TJA) , Accessed: 2025-07-15, n.d.